

MIT6.5840 LAB2A Raft

2024-5-20 · marshall

本文是对MIT6.5840 LAB2A的一份解答。

1 任务描述

实现Raft的时候基本只需要盯住论文中Figure2的图片即可




Figure 2: A condensed summary of the Raft consensus algorithm (excluding membership changes and log compaction). The server behavior in the upper-left box is described as a set of rules that trigger independently and repeatedly. Section numbers such as §5.2

2A部分要求完成的是Raft中的Leader选取和心跳函数, 通过阅读论文和文档, 我们知道Raft的运行状况是这样的:

- 正常运行 Leader不断发送心跳函数给Follower, Follower回复, 这个心跳是通过AppendEntries RPC实现的, 只不过其中entries[]是空的。
- 选举
 1. 当指定的心跳间隔到期时, Follower转化为Candidate并开始进行投票选举, 会为自己投票并自增term
 2. 每一个收到投票请求的Server(即包括了Follower, Candidate或旧的Leader), 判断其RPC的参数是否符合Figure2中的要求, 符合则投票

3. 除非遇到了轮次更靠后的投票申请, 否则投过票的Server不会再进行投票
4. 超过一半的Server的投票将选举出新的Leader, 新的Leader通过心跳AppendEntries RPC宣告自己的存在, 收到心跳的Server更新自己的状态
5. 若超时时间内无新的Leader产生, 再进行下一轮投票, 为了避免这种情况, 应当给不同Server的投票超时设定随机值

2 代码逻辑

通过分析可知, 需要实现的功能包括:

1. 一个协程不断检测一个投票间隔内是接收到心跳或AppendEntries RPC(其实是一个东西), 如果没有接受到, 则发起投票
2. 处理投票的协程, 发起投票并收集投票结果以改变自身角色
3. 不断发送心跳的Leader的心跳发射器协程
4. 处理投票请求的RPC
5. 处理心跳的RPC

官方提供的代码里指明用ticker实现选举, 并给出了RPC的实现案例, 以下给出的代码实现并不包含完整代码, 但是已经覆盖了核心逻辑, 代码已通过单元测试:

```
● marshall@Master:~/Desktop/6.5840/src/raft$ go test -run 3A
Test (3A): initial election ...
... Passed -- 3.6 3 44 10874 0
Test (3A): election after network failure ...
... Passed -- 5.9 3 102 19846 0
Test (3A): multiple elections ...
... Passed -- 6.6 7 612 119294 0
PASS
ok      6.5840/raft      16.106s
```

3 结构体设计

3.1 Raft结构体

```
type Entry struct {
    Term int
    Command interface{}
}

const (
    HeartBeatTimeOut = 150
    ElectTimeOutBase = 500
```

```

    ElectTimeOutCheckInterval = time.Duration(300) * time.Millisecond
)

// A Go object implementing a single Raft peer.
type Raft struct {
    mu      sync.Mutex    // Lock to protect shared access to this peer's state
    peers   []*labrpc.ClientEnd // RPC end points of all peers
    persister *Persister    // Object to hold this peer's persisted state
    me      int           // this peer's index into peers[]
    dead    int32         // set by Kill()
    currentTerm int
    votedFor int
    log []Entry

    commitIndex int
    lastApplied int
    nextIndex []int
    matchIndex []int

    timeStamp time.Time // 记录收到消息的时间（心跳或者append）
    role string

    muVote sync.Mutex    // 保护投票数据
    voteCount int
    // Your data here (3A, 3B, 3C).
    // Look at the paper's Figure 2 for a description of what
    // state a Raft server must maintain.
}

```

1. **role**: 一个枚举量, 记录当前实例的角色, 取值包括: Follower, Candidate, Leader
2. **voteCount**: 得票计数
3. **muVote**: 用于保护**voteCount**的锁, 因为投票时只需要更改**voteCount**, 而全部使用**mu**明细会增加锁的竞争, 这里是细化锁的粒度
4. **timeStamp**: 记录最后一次收到合法消息的时间戳, 每次判断是否要选举时, 通过判断与这个时间戳的差值来决定是否达到超时

为什么不使用定时器**time.Timer**? 主要原因是官方的Hint中明确表示:

Don't use Go's `time.Timer` or `time.Ticker`, which are difficult to use correctly.

因此就选择记录时间戳**timeStamp** + **Sleep**的方式实现

3.2 RPC结构体

```

type RequestVoteArgs struct {
    // Your data here (3A, 3B).
    Term int
    CandidateId int
    LastLogIndex int
    LastLogTerm int
}

```

```
// example RequestVote RPC reply structure.
// field names must start with capital letters!
type RequestVoteReply struct {
    // Your data here (3A).
    Term int
    VoteGranted bool
}

type AppendEntriesArgs struct {
    Term int // leader's term
    LeaderId int // so follower can redirect clients
    PrevLogIndex int // index of log entry immediately preceding new ones
    PrevLogTerm int // term of PrevLogIndex entry
    Entries []Entry // log entries to store (empty for heartbeat; may send more than one for efficiency)
    LeaderCommit int // leader's commitIndex
}

type AppendEntriesReply struct {
    Term int
    Success bool
}
```

4 投票设计

4.1 投票发起方

1. `ticker`函数判断是否需要投票:

```
// ticker 函数判断是否需要投票
func (rf *Raft) ticker() {
    rd := rand.New(rand.NewSource(int64(rf.me)))
    for !rf.killed() {
        rdTimeOut := GetRandomTimeOut(rd)
        rf.mu.Lock()
        if rf.role != "Leader" && time.Since(rf.timeStamp) > time.Duration(rdTimeOut)*time.Millisecond {
            // 超时
            go rf.Elect()
        }
        rf.mu.Unlock()
        time.Sleep(ElectTimeOutCheckInterval)
    }
}
```

这里`timeStamp`就是上一次正常收到消息的时间, 判断当前的时间差再与随机获取的超时时间比较即可

另外, 根据官方的提示可知:

You may find Go's `rand` useful.

确定超时间隔时, 需要为不同的server设置不同的种子, 否则他们大概率会同时开启选票申请, 这里我直接使用其序号rf.me作为随机种子。

2. Elect函数负责处理具体的投票任务:

```
func (rf *Raft) Elect(){
    rf.mu.Lock()

    rf.currentTerm++      // 自增term
    rf.role = "Candidate" // 变成候选人
    rf.votedFor = rf.me    // 给自己投票
    rf.voteCount = 1       // 自己有一票
    rf.timeStamp = time.Now() //自己给自己投票也算一种消息

    args := &RequestVoteArgs{
        Term: rf.currentTerm,
        CandidateId: rf.me,
        LastLogIndex: len(rf.log) - 1,
        LastLogTerm: rf.log[len(rf.log) - 1].Term,
    }

    rf.mu.Unlock()

    for i := 0; i < len(rf.peers); i++ {
        if i == rf.me {
            continue
        }
        go rf.collectVote(i, args)
    }
}
```

这个函数的任务很简单:

- 更新term
- 标记自身角色转换
- 为自己投票
- 初始化票数为1
- 更新时间戳

其余的部分很简单, 就是构造RPC的请求结构体, 异步地对每个server发起投票申请

易错点: 忘记更新时间戳, 因为自己给自己投票也算一种消息, 应当更新时间戳, 否则下一轮投票很快又来了

3. collectVote函数处理每个server的回复并统计票数

```
// collectVote 函数处理每个serve的回复并统计票数
func (rf *Raft) collectVote(serverTo int, args *RequestVoteArgs){
    voteAnswer := rf.GetVoteAnswer(serverTo, args)
    if !voteAnswer{
        return
    }
}
```

```

    }
    rf.muVote.Lock()
    if rf.voteCount > len(rf.peers) / 2 {
        rf.muVote.Unlock()
        return
    }

    rf.voteCount++
    if rf.voteCount > len(rf.peers) / 2 {
        rf.mu.Lock()
        if rf.role == "Follower" {
            // 有另外一个投票的协程收到了更新的term而更改了自身状态为Follower
            rf.mu.Unlock()
            rf.muVote.Unlock()
            return
        }
        rf.role = "Leader"
        rf.mu.Unlock()
        go rf.SendHeartBeats()
    }
    rf.muVote.Unlock()
}

func (rf *Raft) GetVoteAnswer(server int, args *RequestVoteArgs) bool {
    sendArgs := *args
    reply := &RequestVoteReply{}
    ok := rf.sendRequestVote(server, &sendArgs, reply)
    if !ok {
        return false
    }

    rf.mu.Lock()
    defer rf.mu.Unlock()
    if sendArgs.Term != rf.currentTerm {
        return false
    }
    // 如果对方的term比自己大, 那么自己就变成follower
    if reply.Term > rf.currentTerm {
        // 已经是过时的term了
        rf.currentTerm = reply.Term
        rf.role = "Follower"
        rf.votedFor = -1
    }

    return reply.VoteGranted
}

```

collectVote调用GetVoteAnswer, 其中GetVoteAnswer负责处理具体某一个server的回复:

1. 如果RPC调用失败, 直接返回
2. 如果server回复了更大的term, 表示当前这一轮的投票已经废弃, 按照回复更新term、自身角色和投票数据 返回false
3. 然后才是返回server是否赞成了投票

collectVote处理逻辑为:

1. 如果发现当前投票已经结束了(即票数过半), 返回
2. 否则按照投票结果对自身票数自增
3. 自增后如果票数过半, 检查检查状态后转换自身角色为Leader
4. 转换自身角色为Leader, 开始发送心跳

这里特别说明为什么收集投票时需要`muVote`这个锁保护`voteCount`, 因为除了最后一个超过半票的一个协程, 其余协程只需要访问`voteCount`, 因此额外设计了`muVote`这个锁保护它。

易错点:

1. 由于不同函数调用的间隙, 状态可能被别的协程改变了, 因此`GetVoteAnswer`中如果发现`sendArgs.Term != rf.currentTerm`, 表示已经有Leader诞生了并通过心跳改变了自己的Term, 所以放弃投票数据收集
2. `collectVote`中也存在类似的问题, 因为`collectVote`也是与RPC心跳的handler并发的, 可能新的Leader已经产生, 并通过心跳改变了自己的role为Follower, 如果不检查的话, 将导致多个Leader的存在
3. 尽管向多个server发送的`RequestVoteArgs`内容是相同的, 但我们不同使用同一个指针, 而是应该复制一个结构体 否则会报错, 原因暂时没看源码, 未知(先鸽了)

4.2 投票接收方

```
func (rf *Raft) RequestVote(args *RequestVoteArgs, reply *RequestVoteReply) {
    // Your code here (3A, 3B).  rf.mu.Lock()
    rf.mu.Lock()

    if args.Term < rf.currentTerm {
        // 对方的term比自己小
        reply.Term = rf.currentTerm
        rf.mu.Unlock()
        reply.VoteGranted = false
        return
    }

    if args.Term > rf.currentTerm {
        // 已经是新一轮的term, 之前的投票记录作废
        rf.votedFor = -1
        rf.currentTerm = args.Term
        rf.role = "Follower"
    }

    if rf.votedFor == -1 || rf.votedFor == args.CandidateId {
        // 首先确保是没投过票的
        if args.LastLogTerm > rf.log[len(rf.log)-1].Term ||
            (args.LastLogIndex >= len(rf.log) - 1 && args.LastLogTerm == rf.log[len(rf.log) - 1].Term) {
            // 对方的term比自己大, 或者对方的term和自己一样大但是对方的log比自己新
            rf.currentTerm = args.Term
            reply.Term = rf.currentTerm
            rf.votedFor = args.CandidateId
            rf.role = "Follower"
        }
    }
}
```

```

        rf.timeStamp = time.Now()

        rf.mu.Unlock()
        reply.VoteGranted = true
        return
    }
} else {
    // fmt.Printf("Server %v has voted for %v\n", rf.me, rf.votedFor)
}

reply.Term = rf.currentTerm
rf.mu.Unlock()
reply.VoteGranted = false
}

```

代码的逻辑是:

1. 如果`args.Term < rf.currentTerm`, 直接拒绝投票, 并告知更新的投票
2. 如果`args.Term > rf.currentTerm`, 更新`rf.votedFor = -1`, 表示自己没有投票, 之前轮次的投票作废
3. 如果满足下面两个情况之一, 投票, 然后更新`currentTerm`, `votedFor`, `role`, `timeStamp`
 1. `args.Term > rf.currentTerm`
 2. `term == currentTerm`且`LastLogTerm`和`LastLogIndex`位置的条目存在且`term`合法, 并且未投票或者投票对象是自己
4. 其他情况不投票

易错点 `args.Term > rf.currentTerm`的情况需要设置`rf.votedFor = -1`, 因为当前的`server`可能在正处于旧的`term`的选举中, 并投给了别人, 应当废除旧`term`的投票, 将其置为未投票的状态, 否则将错失应有的投票

5 心跳设计(AppendEntries RPC)

5.1 心跳发射器

当一个`Leader`诞生时, 立即启动心跳发射器, 其不断地调用`AppendEntries` RPC, 只是`Entries`是空的而已, 其代码相对简单:

```

func (rf *Raft) SendHeartBeats(){
    // fmt.Printf("Server %v is sending heartbeats\n", rf.me)

    for !rf.killed(){
        rf.mu.Lock()
        // if the server is dead or is not a leader, just return
        if rf.role != "Leader" {
            rf.mu.Unlock()
            return
        }

        args := &AppendEntriesArgs{

```

```

        Term: rf.currentTerm,
        LeaderId: rf.me,
        PrevLogIndex: 0,
        PrevLogTerm: 0,
        Entries: nil,
        LeaderCommit: rf.commitIndex,
    }

    rf.mu.Unlock()

    for i := 0; i < len(rf.peers); i++ {
        if i == rf.me {
            continue
        }
        go rf.handleHeartBeats(i, args)
    }

    time.Sleep(time.Duration(HeartBeatTimeOut) * time.Millisecond)
}

```

易错点: 同前文描述, 尽管向多个server发送的AppendEntriesArgs内容是相同的, 但我们不能使用同一个指针, 而是应该复制一个结构体 否则会报错

```

func (rf *Raft) handleHeartBeats(serverTo int, args *AppendEntriesArgs){
    reply := &AppendEntriesReply{}
    sendArgs := *args
    ok := rf.sendAppendEntries(serverTo, &sendArgs, reply)

    if !ok {
        return
    }

    rf.mu.Lock()
    defer rf.mu.Unlock()

    if sendArgs.Term != rf.currentTerm {
        return
    }

    if reply.Term > rf.currentTerm {
        // fmt.Printf("Server %v the old leader has received the updated Term: %v, trans to Follower\n", rf.me, reply.Term)
        rf.currentTerm = reply.Term
        rf.votedFor = -1
        rf.role = "Follower"
    }
}

```

handleHeartBeat负责处理每一个发出的心跳函数的回复, 只需要考虑的就是自身的term被更新了, 需要更改自身状态, 其逻辑和前文相同, 不赘述

易错点 这里也存在函数调用间隙字段被修改的情况, 也需要检查sendArgs.Term != rf.currentTerm的情况

5.2 心跳接受方

心跳接受方实际上就是AppendEntries RPC的handler, 由于目前日志部分的字段还没有设计, 因此这里的代码不涉及持久化:

```
func (rf *Raft) AppendEntries(args *AppendEntriesArgs, reply *AppendEntriesReply){
    rf.mu.Lock()

    if args.Term < rf.currentTerm {
        // 这是来自旧 leader的消息
        reply.Term = rf.currentTerm
        rf.mu.Unlock()
        reply.Success = false
        return
    }

    // 记录访问时间
    rf.timeStamp = time.Now()

    if args.Term > rf.currentTerm {
        rf.currentTerm = args.Term
        rf.votedFor = -1
        rf.role = "Follower"
    }

    if args.Entries == nil {
        // 心跳函数
        // fmt.Printf("Server %v has received heartbeats from leader %v\n", rf.me, args.LeaderId)
    }

    if args.Entries != nil &&
        (args.PrevLogIndex >= len(rf.log) || rf.log[args.PrevLogIndex].Term != args.PrevLogTerm) {
        // 校验PrevLogIndex和PrevLogTerm
        reply.Term = rf.currentTerm
        rf.mu.Unlock()

        reply.Success = false
        return
    }

    // TODO: 补充append业务

    reply.Success = true
    reply.Term = rf.currentTerm

    if args.LeaderCommit > rf.commitIndex {
        rf.commitIndex = int(math.Min(float64(args.LeaderCommit), float64(len(rf.log) - 1)))
    }

    rf.mu.Unlock()
}
```

1. 如果term < currentTerm表示这是一个旧leader的消息, 告知其更新的term并返回false
2. 如果自己的日志中prevLogIndex处不存在有效的日志, 或者与prevLogTerm不匹配, 返回false

3. 如果现存的日志与请求的信息冲突, 删除冲突的日志(这一部分不涉及)
4. 添加日志(这一部分不涉及)
5. 如果`leaderCommit > commitIndex`, 确认者较小值并更新

同时, 收到`AppendEntries`需要更新对应的时间戳`rf.timeStamp`

易错点

1. 如果`args.Term > rf.currentTerm`, 表示这是新的Leader发送的消息, 由于自身可能正在进行选举投票, 因此需要更改`rf.role = Follower` && `rf.votedFor = -1`以终止其不应该继续的投票, 同时更新`rf.votedFor = -1`, -1表示未投过票。