

数据结构——散列表

2024-9-13 · marshall

对散列表数据结构的简单分析记录

- 一、什么是Hash表
- 二、哈希函数的构造方法
- 三、哈希冲突
 - 公共溢出区法
 - 再散列法
 - 开放寻址法
- 四、hash表的查找
- 五、hash表的删除

一、什么是Hash表

Hash函数：地址 $\text{index} = H(\text{key})$

说白了，hash函数就是根据key计算出应该存储地址的位置，而哈希表是基于哈希函数建立的一种查找表。

二、哈希函数的构造方法

根据前人经验，统计出如下几种常用hash函数的构造方法：

直接定址法

直接定址法（Direct Addressing）是一种特殊的哈希函数，它将关键字直接映射到哈希表的索引上。这种方法适用于关键字集合的大小与哈希表的大小相等的情况。下面我将提供一个更直观的例子来说明直接定址法。

假设一个图书馆有一本特殊的书籍，这本书记录了该图书馆所有书籍的索引信息。每本书都有一个唯一的ISBN号，我们可以用这个ISBN号作为关键字来构建哈希表。

1. 哈希表大小：假设哈希表有100个槽位（索引从0到99）。
2. 哈希函数：我们可以定义一个简单的哈希函数，将ISBN号的最后两位数字直接用作索引。哈希函数可以表示为 $H(\text{ISBN}) = (\text{ISBN} \% 100)$ ，其中ISBN是书籍的ISBN号。

假设有以下几本书的ISBN号：

- 978-0-306-40615-7
- 978-1-4028-9462-6
- 978-0-387-34586-9

计算哈希值：

- 对于第一本书， $H(978-0-306-40615-7) = (978030640615 \% 100) = 15$
- 对于第二本书， $H(978-1-4028-9462-6) = (978140289462 \% 100) = 62$
- 对于第三本书， $H(978-0-387-34586-9) = (978038734586 \% 100) = 86$

哈希表建立

index	ISBN	书名
15	978-0-306-40615-7	"Book A"
62	978-1-4028-9462-6	"Book B"
86	978-0-387-34586-9	"Book C"

在这个例子中，我们可以看到直接定址法如何将ISBN号映射到哈希表的索引上。这种方法的优点是简单且直接，但缺点是哈希表的大小必须与关键字集合的大小相匹配，这在实际应用中可能不太灵活。

数学分析法

假设关键字集合中的每个关键字key都是由s位数字组成 $(k_1, k_2, \dots, k_n)$ ，分析key中的全体数据，并从中提取分布均匀的若干位或他们的组合构成全体

我们知道身份证号是有规律的，现在我们要存储一个班级学生的身份证号码，假设这个班级的学生都出生在同一年，同一年，那么他们的身份证的前面数位都是相同的，那么我们可以截取后面不同的几位存储，假设有5位不同，那么就用这五位代表地址。 $H(key) = key \% 100000$ 此种方法通常用于数字位数较长的情况，必须数字存在一定规律，其必须知道数字的分布情况，比如上面的例子，我们事先知道这个班级的学生出生在同一年，同一个地区。

平方取中法

如果关键字的每一位都有某些数字重复出现频率很高的现象，可以先求关键字的平方值，通过平方扩大差异，而后取中间数位作为最终存储地址。

比如key=1234 $1234^2=1522756$ 取227作hash地址

比如key=4321 $4321^2=18671041$ 取671作hash地址

这种方法适合事先不知道数据并且数据长度较小的情况

$H(key) = \text{floor}((key^2 / (10^k)) \bmod m)$ 其中 k 是一个常数，用于控制取多少位。

折叠法

当关键字位数较多时，可以将其分成几部分，然后对每部分进行哈希，最后将这些哈希值合并。

例如，可以将关键字分成高位和低位两部分，分别计算哈希值，然后合并。

除留余数法

除留余数法用的较多 $H(key) = key \bmod p$ ($p \leq m$ m为表长) 很明显，如何选取p是个关键问题。

比如我们存储3 6 9，那么p就不能取3

因为 $3 \bmod 3 == 6 \bmod 3 == 9 \bmod 3$

p应为不大于m的质数或是不含20以下的质因子的合数，这样可以减少地址的重复（冲突）

比如key = 7, 39, 18, 24, 33, 21时取表长m为9 p为7 那么存储如下

index	0	1	2	3	4	5	6	7	8
key	7	21 (冲突 后移)		24	39	18 (冲突 后移)	33 (冲突 后移)		

随机法

在某些情况下，可以使用随机数来构造哈希函数，以增加哈希值的随机性和均匀性。例如，可以生成一个随机的哈希表，其中每个槽位都有一个随机的哈希函数。

$H(key) = \text{Random}(key)$ 取关键字的随机函数值为它的散列地址

hash函数设计的考虑因素

1. 计算散列地址所需要的时间（即hash函数本身不要太复杂）
2. 关键字的长度
3. 表长
4. 关键字分布是否均匀，是否有规律可循
5. 设计的hash函数在满足以上条件的情况下尽量减少冲突

三、哈希冲突

公共溢出区法

建立一个特殊存储空间，专门存放冲突的数据。此种方法适用于数据和冲突较少的情况。

再散列法

准备若干个hash函数，如果使用第一个hash函数发生了冲突，就使用第二个hash函数，第二个也冲突，使用第三个.....

开放寻址法

首先有一个H (key) 的哈希函数

如果 $H(key_1) = H(key_i)$

那么 key_i 存储位置 $H_i = (H(key) + d_i) \text{MOD } m$, m为表长。

d_i 有三种取法


1. 线性探测再散列 $d_i = c * i$
2. 平方探测再散列 $d_i = 1^2, (-1)^2, 2^2, (-2)^2$
3. 随机探测再散列（双探测再散列） d_i 是一组伪随机数列

注意，增量 d_i 应该具有以下特点（完备性）：产生的 H_i （地址）均不相同，且所产生的s (m-1) 个 H_i 能覆盖hash表中的所有地址

1. 平方探测时表长m必须为 $4j+3$ 的质数（平方探测表长有限制）
2. 随机探测时m和 d_i 没有公因子（随机探测 d_i 有限制）

链地址法

产生hash冲突后在存储数据后面加一个指针，指向后面冲突的数据：



四、hash表的查找

查找过程和造表过程一致，假设采用开放定址法处理冲突，则查找过程为：

对于给定的key，计算hash地址 $index = H(key)$

如果数组arr【index】的值为空 则查找不成功

如果数组arr【index】== key 则查找成功

否则 使用冲突解决方法求下一个地址，直到arr【index】== key或者 arr【index】==null

hash表的查找效率

决定hash表查找的ASL(Average Search Length)因素：

1. 选用的hash函数
2. 选用的处理冲突的方法
3. hash表的饱和度，装载因子 $\alpha = n/m$ (n表示实际装载数据长度 m为表长)

一般情况，假设hash函数是均匀的，则在讨论ASL时可以不考虑它的因素 hash表的ASL是处理冲突方法和装载因子的函数 前人已经证明，查找成功时如下结果：

线性探测再散列

$$S_{nl} \approx \frac{1}{2} \left(1 + \frac{1}{1-\alpha} \right)$$

随机探测再散列

$$S_{nr} \approx -\frac{1}{\alpha} \ln(1-\alpha)$$

链地址法


$$S_{nc} \approx 1 + \frac{\alpha}{2}$$

可以看到无论哪个函数，装载因子越大，平均查找长度越大，那么装载因子 α 越小越好？也不是，就像100的表长只存一个数据， α 是小了，但是空间利用率不高啊，这里就是时间空间的取舍问题了。通常情况下，认为 $\alpha=0.75$ 是时间空间综合利用效率最高的情况。

上面的这个表可是特别有用的。假设我现在有10个数据，想使用链地址法解决冲突，并要求平均查找长度 <2 那么有 $1+\alpha/2 < 2$ $\alpha < 2$ 即 $n/m < 2$ ($n=10$) $m > 10/2$ $m > 5$ 即采用链地址法，使得平均查找长度 <2 那么 $m > 5$

hash表的ASL是基于装载因子的函数，也就是说，当数据 n 增加时，我可以通过增加表长 m ，以维持装载因子不变，确保ASL不变。

那么hash表的构造应该是这样的：



五、hash表的删除

链地址法：每个哈希槽位对应一个链表，删除元素只影响该链表，不影响其他元素的查找。

开放定址法：所有元素直接存储在哈希表的槽位中。删除元素时，不能简单地将槽位留空，因为这会打断探测序列，导致无法找到后续插入的元素。正确的做法是使用一个特殊值或标记（如-1）来表示该槽位的元素已被删除，从而保持探测序列的完整性。

参考

1. 数据结构（严蔚敏）
2. <https://blog.csdn.net/u011109881/article/details/80379505>